## #4EduTech Pipeline обработки данных

### Получение данных, преобразование из формата CSV в формат SQL

Данные были предоставлены файлами CSV, т.к. в будущем проект будет получать данные непосредственно из базы данных клиента, делать автоматическую загрузку не было смысла. В процессе работы с данными были сделаны предварительные изменения с названиями полей

### users\_age\_timezone.csv

userID	timeZone	age
982	+03:00	16
2566	+03:00	16
2614	+03:00	15

#### Table: users\_age\_timezone

Название	#	Тип данных
123 user_id	- 1	int4
ABC time_zone	2	varchar(50)
123 age	3	int4

#### **CSV:** authorization.csv

user_i			window_siz
d	created_at	user_agent	е
		Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like	
7722	2022-12-07 17:43:14	Gecko) Chrome/106.0.0.0 YaBrowser/22.11.0.2500 Yowser/2.5 Safari/537.36	1872x932
		Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like	
7722	2022-12-07 19:51:34	Gecko) Chrome/106.0.0.0 YaBrowser/22.11.0.2500 Yowser/2.5 Safari/537.36	1872x918
		Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like	
2614	2022-12-08 00:59:43	Gecko) Chrome/106.0.0.0 YaBrowser/22.11.0.2500 Yowser/2.5 Safari/537.36	1528x755

#### **Table: authorization**

Название	#	Тип данных
123 user_id	1	int4
created_at	2	timestamp
ABC user_agent	3	varchar(256)
ABC window_size	4	varchar(50)

#### **CSV: schedule.csv**

		taski	activivtyl	activityTyp	isAttestatio	visibilit	flow	
course_id	type	D	D	е	n	у	S	dateShown
	активност							
3	ь	81	8719	slide	0	{}	1	2023-12-05 11:00:00
	активност							
3	ь	81	8720	slide	0	{}	1	2023-12-05 11:00:00
	активност							
3	ь	81	8722	slide	0	{}	1	2023-12-05 11:00:00

### Table: schedule

#	Тип данных
- 1	int4
2	varchar(50)
3	int4
4	int4
5	varchar(50)
6	int4
7	varchar(50)
8	int4
9	timestamp
	1 2 3 4 5 6 7 8

CSV: activity\_history\_viewed.csv

user_i		page_typ	page_i	modul	attestatio	activity_typ
a	created_at	е	a	е	n	е
982	2024-01-24 19:14:11	занятие	3015	2	1	
982	2024-01-24 19:34:09	занятие	3015	2	1	
982	2024-01-28 22:35:18	занятие	3015	2	1	

# Table: activity\_history\_viewed

Название	#	Тип данных
123 user_id	- 1	int4
created_at	2	timestamp
ABC page_type	3	varchar(50)
123 page_id	4	int4
123 module	5	int4
123 attestation	6	int4
ABC activity_type	7	varchar(50)

## **CSV:** webinars\_logs.csv

		eventNam	webinarl			
userId	dateTime	e	d	формат подключения	вводный вебинар	module
74952	2023-12-23 12:10:03	Подключение	13378	офлайн	1	2
74952	2023-12-23 12:15:44	Отключение	13378	офлайн	1	2
74952	2023-12-23 12:20:58	Подключение	13378	офлайн	1	2

# Table: webinars\_logs

Название	#	Тип данных
123 user_id	- 1	int4
datetime	2	timestamp
ABC event_name	3	varchar(50)
123 webinar_id	4	int4
ABC conn_format	5	varchar(50)
123 webinar_vvod	6	int4
123 module	7	int4

# CSV: exercise\_results.csv

modul	activityl				succes
е	D	userId	createdAt	result	S
2	13278	72002	2023-12-01 08:53:00	100	1
2	13278	66421	2023-12-01 09:18:55	100	1
2	13278	66405	2023-12-01 09:23:24	100	1

## Table: exercise\_results

Название	#	Тип данных
123 module	1	int4
123 activity_id	2	int4
123 user_id	3	int4
created_at	4	timestamp
ABC result	5	varchar(50)
123 success	6	int4

## CSV: users\_logs.csv

user_i d	created_at	event	comment
2566	2023-11-14 15:07:40	tags-changed	Были хештеги: #entry-email #офлайн, стали: #entry-email #онлайн

			Были хештеги: #мотив #онлайн #М1-завершил #сверка-дат #М1-оплачен #М2-завершил, стали:
2614	2024-02-19 17:20:49	tags-changed	#мотив #онлайн #M1-завершил #M1-оплачен #M2-завершил
			Были хештеги: #онлайн #М1-завершил #сверка-дат #М1-оплачен #М2-завершил, стали:
13849	2024-02-19 17:22:00	tags-changed	#онлайн #М1-завершил #М1-оплачен #М2-завершил

Название	#	Тип данных
123 user_id	- 1	int4
created_at	2	timestamp
ABC event	3	varchar(50)
ABC comment	4	varchar(256)

### **CSV:** users.csv

	userl	course i	flow_nu		M2_progres	M2_attestatio	
unti id	D	d	m	tgBot	s	n	M2_attestation_date
u			•••	1,5201		••	
1051004	982	3	1.00	-	13	Не сдана	
1118021	2566	3	1.00	_	0	Не сдана	
				подключе			
1120146	2614	77	1.00	н	100	80	2024-03-05 17:29:37

# Table: users

Название	#	Тип данных
123 unti_id	1	int4
123 user_id	2	int4
123 course_id	3	int4
123 flow_num	4	float4
ABC tg_bot	5	varchar(50)
ABC m2_progress	6	varchar(50)
MBC m2_attestation	7	varchar(50)
m2_attestation_date	8	timestamp

## **CSV:** activities\_guide.csv

courseID	Курс	Провайдер	Модуль	themeID	Тема	taskID	Занятие	Task	Признак	activityID
								Position	Аттестации	
3	Нейро.РҮ	1T	2	13	Функции	81	Функции графики и	1	0	14823
					и классы		запроса данных			
3	Нейро.РҮ	1T	2	13	Функции	81	Функции графики и	1	0	14824
					и классы		запроса данных			
3	Нейро.РҮ	1T	2	13	Функции	81	Функции графики и	1	0	14825
					и классы		запроса данных			

#### продолжение

Тип Активности	Активность	Признак Обязательного	Видимость
CodeExercise	Тренажер 1	0	{}
CodeExercise	Тренажер 2	0	{}
CodeExercise	Тренажер 3	0	{}

Table: activities\_guide

Название	#	Тип данных
123 course_id	1	int4
ABC course	2	varchar
ABC provider	3	varchar
123 modul	4	int4
123 theme_id	5	int4
ABC theme	6	varchar
123 task_id	7	int4
ABC exercise	8	varchar
123 task_position	9	int4
123 att_priznak	10	int4
123 activity_id	11	int4
ABC activity_type	12	varchar
ABC activity	13	varchar
123 obyaz_priznak	14	int4
ABC visibility	15	varchar

### Работа с данными в базе PostgreSQL

Фильтр выборки обучающихся по данным был задан заказчиком, брать тех кто имеет статус онлайн

```
with
t1 as(
select distinct user_id, created_at, comment
from public.users_logs logs
where comment like 'Были хештеги:%онлайн%стали:%онлайн%'
   or comment like 'Установлен хештег "#онлайн"' --'%Установлен%онлайн%'
   or comment like 'Были хештеги: , стали:%онлайн%'
   or comment like 'Были хештеги%оулайн%стали:%онлайн%'
   or comment like 'Были хештеги%оглайн%стали:%онлайн%')

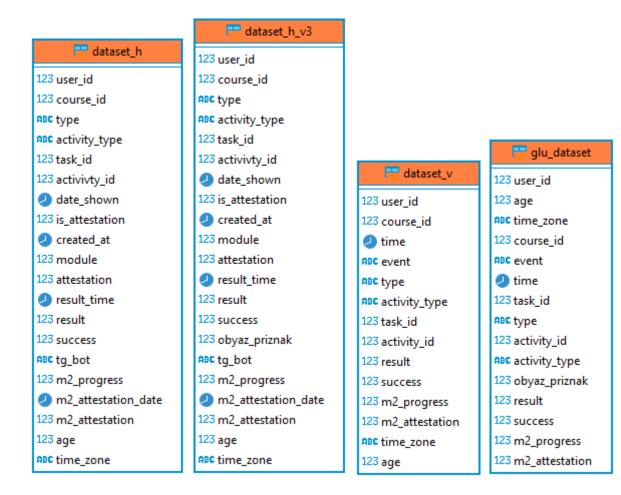
select *
from users
where "userID" in(select distinct user_id from t1)
```

@TatianaGlu

В процессе работы с данными аналитиками были сформированы представления по которым проверялись гипотезы

Коллеги, позволил себе нескромность сделать новые вьюшки из датасетов, которые собрали мы с Таней. По крайней мере мне так удобнее пользоваться, если работать напрямую с базой. dataset\_v - 1й датасет, где все даты расположены по вертикали (V) dataset\_h - 2й датасет, где часть событий сопоставлена по горизонтали (H) Важное уточнение! Убрал в 1м датасете фильтрацию только успешных студентов (строк стало больше), но сохранил фильтрацию тех студентов, по которым есть след во всех таблицах. 2й датасет сразу был собран по такому принципу.

@ryurikovich\_37



Новую версию сохранил как dataset\_h\_v3 Изменения:

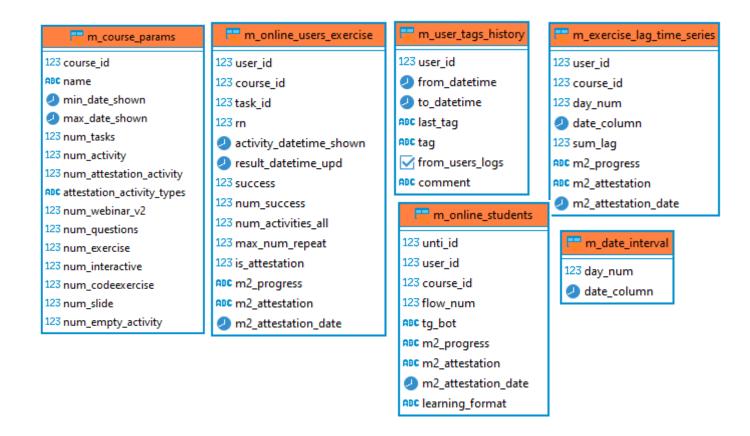
- 1) Данные на основе датасета students\_v3 (см. выше)
- 2) Не стал выкидывать студентов, которые засветились не во всех таблицах
- 3) Добавил столбец обязательного признака задания

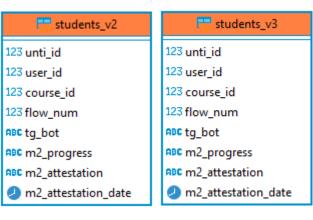
Датасет стал тяжелым (1 217 959 строк), выполняется долго.

@ryurikovich\_37

```
rith
cross_schedule as (
salect sv2_user_id, sv.course_id, sv."type", sv.activity_type, sv.task_id, sv.activity_id, sv.date_shown, sv.is_attestation
from schedule_v2 sv
n sv2_course_id = sv.course_id
), cross_shistory as (
salect
cross_schedule_user_id, cross_schedule.course_id, cross_schedule.*type*, cross_schedule.activity_type, cross_schedule.task_id,
cross_schedule_activivty_id, cross_schedule_date_shown , cross_schedule.is_attestation,
ahvv.created_at , ahvv."module* , ahvv.attestation
from cross_schedule
left join activity_history_viewed_v2 ahvv
on (ahvv.user_id = cross_schedule_user_id) and (ahvv.page_id = cross_schedule.task_id)
where type = 'anwarwe'
union
salect cross_schedule_activivty_id, cross_schedule_course_id, cross_schedule.*type*, cross_schedule_activity_type, cross_schedule.task_id,
ahvv.created_at , ahvv."module* , ahvv.attestation
from cross_schedule.activivty_id, cross_schedule_date_shown , cross_schedule.is_attestation,
ahvv.created_at , ahvv."module* , ahvv.attestation
from cross_schedule
left join activity_history_viewed_v2 ahvv
on (ahvv.user_id = cross_schedule_user_id) and (ahvv.page_id = cross_schedule_activivty_id)
where type = 'arrameorts')
history_results as (
select cross_inistory.*, erv.created_at as result_time,
case when erv.result = 'hponyck' then -1 else cast(erv.result as int4) end as result,
erv. success
from cross_history.
left join exercise_results_v2 erv
on (erv.user_id = cross_history_user_id) and (erv.activity_id = cross_history_activivty_id)
)

select history_results.*, agv.obyaz_priznak, sv.tg_bot,
case when sv.m2_trostation = 'Her gannux' then -1 else cast(sv.m2_progress as inti) end as m2_progress,
sv.m2_attestation_date,
case when sv.m2_attestation = 'Her gannux' then -1 else cast(sv.m2_attestation as int4) end as m2_progress,
sv.m2_attestation_date,
case when sv.m2_attestation = 'Her gannux' then -1 else cast(sv.m2_attestation as int4) end as m2_attestation,
untv.age, untv.time_crome
from history_results.user_id = lattv.user_id
eff join activity_id = history_res
```





По представлениям много было испробовано и отброшено общим решением DA, после долгих споров, анализов и уточнений у заказчиков оставили текущие версии.

запросы, которыми формировали стартовые датасеты?

```
интересно, как считали sum_m2_progress и остальные значения with events as(
```

select user\_id, created\_at as time, 'authorization' as event, " as type, " as activity\_type, O as task\_id, O as activity\_id, O as result, O as success, O as m2\_progress, O as

```
m2_attestation from authorization_v2 av
```

where user\_id in (select user\_id from public.students\_v3)

union

select user\_id, created\_at as time, event, "as type, "as activity\_type, 0 as task\_id, 0 as activity\_id, 0 as result, 0 as success, 0 as m2\_progress, 0 as m2\_attestation from users\_logs\_v2 ulv

where user\_id in (select user\_id from public.students\_v3)

union

select user\_id, m2\_attestation\_date as time, 'attestation' as event, " as type, " as activity\_type, 0 as task\_id, 0 as activity\_id, 0 as result, 0 as success, case when m2\_progress = 'Heт данных' then -1 else cast(m2\_progress as int4) end as m2\_progress, case when m2\_attestation = 'He сдана' then -1 else cast(m2\_attestation as int4) end as m2\_attestation

from students\_v2

```
where user_id in (select user_id from public.students_v3)
                select user_id, created_at as time, 'history' as event, page_type as type, activity_type, 0 as task_id, null as activity_id, 0 as result, 0 as success, 0 as m2_progress, 0 as
m2_attestation
                from public.activity_history_viewed_v2
                where (page_type = '3ahatue') and (user_id in (select user_id from public.students_v3))
               union
                select ahvv.user_id, ahvv.created_at as time, 'history' as event, page_type as type, ahvv.activity_type
                , sv.task_id as task_id, ahvv.page_id as activity_id, 0 as result, 0 as success, 0 as m2_progress, 0 as m2_attestation
                from public.activity history viewed v2 ahvv
                left join schedule_v2 sv on ahvv.page_id = sv.activivty_id
                where (ahvv.page_type = 'активность') and (ahvv.user_id in (select user_id from public.students_v3))
               select user_id, created_at as time, 'results' as event, " as type, " as activity_type, 0 as task_id, activity_id,
                case when result = 'Пропуск' then -1 else cast(result as int4) end as result, success as success, 0 as m2_progress, 0 as m2_attestation
               from public.exercise_results_v2 erv
                where user_id in (select user_id from public.students_v3)
                select user_id, datetime as time, event_name as event, 'Be6uHap' as type, " as activity_type, 0 as task_id, webinar_id as activity_id, 0 as result, 0 as success, 0 as
m2_progress, 0 as m2_attestation
               from public.webinars_logs_v2
               where user_id in (select user_id from public.students_v3)
               --выбираем юзеров сдавших аттестацию по модулю вовремя
               success_intime_users as(
               select user_id from public.users_v2 --where m2_attestation_date between '2023-12-01 00:00:00.000' and '2024-02-01 00:00:00.000' закомментили для неуспешных
               )
               --собрали user_id, кто сдал аттестацию
               success_users as(
               select user_id from events where m2_attestation >= 50 and m2_progress >=50 and user_id in (select user_id from success_intime_users)
               --подтягиваем номер группы, часовой пояс и возраст
               events_with_personal_info as(
               select ev.user_id, users.course_id, ev.time, ev.event, ev.type, ev.activity_type, ev.task_id, ev.activity_id, ev.result, ev.success, ev.m2_progress, ev.m2_attestation
                , uat.time_zone, uat.age
                from events ev
                left join public.users v2 users
                on ev.user_id=users.user_id
               left join public.users_age_timezone_v2 uat
                on ev.user_id=uat.user_id
               select 0 as user id, course id, date shown as time, 'schedule' as event, type, activity type, task id, activity id, 0 as result, 0 as success, 0 as m2 progress, 0 as
m2_attestation, " as time_zone, 0 as age
               from public.schedule_v2 sv2
               order by user_id, time
               --выбрали юзеров из 49 группы успешно сдавших модуль и разбили их по неделям
               dataset_vsev_suc as(
               select user id, age
               , date_part('year', time) as year, date_part('week', time) week
               -- , count(event) filter (where event = 'authorization') authorization_count
                , count(event) filter (where event = 'history') all_activity_count
                . count(event) filter (where event = 'attestation') attestation event count
               , count(event) filter (where event = 'results') results_event_count
               -- , count(activity_type) filter (where activity_type = 'CodeExercise') "CodeExercise_count"
```

```
-- , count(activity_type) filter (where activity_type = 'interactive') interactive_count
-- , count(activity_type) filter (where activity_type = 'slide') slide_count
-- , count(activity_type) filter (where activity_type = 'exercise') exercise_count
, sum(result) total_score
, sum(success) success_attempts
 , count(success) total_attempts
, round((1.0*sum(success)/count(success)), 2) success_rate --удачные попытки / все попытки
, case when sum(success)!= 0 then 1.0*sum(result)/sum(success) else 0 end as avg_success_scare --cp.балл удачных попыток сдачи
, case when count(success)!= 0 then 1.0*sum(result)/count(success) else 0 end as avg_scare --средний балл всех попыток сдачи заданий
, sum(m2_progress) sum_m2_progress
from events_with_personal_info
where user_id in(select user_id from success_users) and user_id != 0
and course_id=49
and date_part('week', time) in(1, 2, 3, 4, 5, 48, 49, 50, 51, 52)
group by user_id, year, week, age
order by user_id, year, week
select * from dataset_vsev_suc
```

@TatianaGlu

20241024\_dataset\_timeseries\_with\_metrics\_v\_gavrilova 123 id 123 user\_id 123 payment 123 time\_zone 123 age 123 unti\_id 123 course\_id 123 flow\_num 123 tg\_bot 123 m2\_progress 123 m2\_attestation 123 module 123 m2\_delay 123 sum\_auth 123 sum\_schedule\_activities 123 sum\_required\_activity 123 sum\_attestation\_activity 123 view\_delay\_first 123 view\_delay\_sum 123 sum\_activity\_viewed 123 sum\_required\_activity\_viewed 123 sum\_attestation\_activity\_viewed 123 w\_view\_hours 123 sum\_exercise 123 sum\_required\_exercises 123 sum\_attestation\_exercises 123 exercise\_delay\_first 123 exercise\_delay\_sum 123 result\_delay\_mean 123 result\_delay\_sum 123 sum\_exercise\_attempts\_mean 123 mean\_required\_result 123 mean\_non\_req\_result 123 mean\_attestation\_result 123 sum\_result 123 conn 123 online\_rate 123 mean\_result

Одно из представлений сделали таблицей и вывели в общее использование.

### Работа DS над данными

123 progress RBC cur\_date

Код разработан пользователем с телеграмм username @zloy

## Прогнозирование показателя результативности обучения на курсах

Исходные данные: выборки, содержащие показатели прохождения курса обучающимися.

1. course\_49\_lubov\_dataset.csv - датасет с данными учеников 49 группы.

Задача: используя модели машинного обучения, спрогнозировать показатель результативности прохождения курса.

m2_delay_7_wee	m2_delay_6_week	m2_delay_5_week	m2_delay_4_week	m2_delay_3_week	m2_delay_2_week	m2_delay_1_week	age	user_id
-58.45833	-58.458332	-58.458332	-58.458332	-58.458332	-58.458332	-58.458332	15	23052
-58.45833	-58.458332	-58.458332	-58.458332	-58.458332	-58.458332	-58.458332	15	29079
view_delay_first_6_w	view_delay_first_5_w	view_delay_first_4_w	view_delay_first_3_w	view_delay_first_2_w	view_delay_first_1_w	m2_delay_10_week	m2_delay_9_week	m2_delay_8_week
0.	0.0	0.0	0.0	0.0	0.0	-58.458332	-58.458332	-58.458332
0.	0.0	0.0	0.0	0.0	0.0	-58.458332	-58.458332	-58.458332
view_delay_sum_5_w.	view_delay_sum_4_w	view_delay_sum_3_w	view_delay_sum_2_w	view_delay_sum_1_w	view_delay_first_10	view_delay_first_9_w	view_delay_first_8_w	view_delay_first_7_w
0.	0.0	0.0	0.0	0.0	-0.17836145	-0.17836145	-0.17836145	-0.18401042
0.	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
sum_activity_viewed	sum_activity_viewed	sum_activity_viewed	sum_activity_viewed	view_delay_sum_10	view_delay_sum_9_w	view_delay_sum_8_w	view_delay_sum_7_w	ew_delay_sum_6_w
0.	0.0	0.0	0.0	-24.888681	-24.888681	-24.888681	-15.484445	0.0
0.	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
sum_required_activity	sum_required_activity	sum_required_activity	sum_activity_viewed	sum_activity_viewed	sum_activity_viewed	sum_activity_viewed	sum_activity_viewed	um_activity_viewed
0.	0.0	0.0	111.0	111.0	111.0	70.0	0.0	0.0
				-70	2.00	'		
sum_exercise_1_wee	sum_required_activity	sum_required_activity	sum_required_activity	sum_required_activity	sum_required_activity	sum_required_activity	sum_required_activity	sum_required_activity
0.	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
0.	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
sum_exercise_10_wee	sum_exercise_9_week	sum_exercise_8_week	sum_exercise_7_week	sum_exercise_6_week	sum_exercise_5_week	sum_exercise_4_week	sum_exercise_3_week	sum_exercise_2_week
0.	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
0.	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
sum_required_exerci.	sum_required_exerci	sum_required_exerci	sum_required_exerci	sum_required_exerci	sum_required_exerci	sum_required_exerci	sum_required_exerci	sum_required_exerci
0.	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
0.	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
•	0.0	0.0	0.0	0.0	3.0	0.0	0.0	0.0
exercise_delay_first	exercise_delay_first	exercise_delay_first	exercise_delay_first	exercise_delay_first	exercise_delay_first	exercise_delay_first	exercise_delay_first	sum_required_exerci
8.82738	4.7916665	0.0	0.0	0.0	0.0	0.0	0.0	0.0
0.	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
exercise_delay_sum	exercise_delay_sum	exercise_delay_sum	exercise_delay_sum	exercise_delay_sum	exercise_delay_sum	exercise_delay_sum	exercise_delay_first	exercise_delay_first
19.16666	0.0	0.0	0.0	0.0	0.0	0.0	22.827381	15.827381
0.	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
result_delay_sum_7	result_delay_sum_6	result_delay_sum_5	result_delay_sum_4	result_delay_sum_3	result_delay_sum_2	result_delay_sum_1	exercise_delay_sum	cercise_delay_sum
0	0.0	0.0	0.0	0.0	0.0	0.0	159.79167	110.791664
0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
sum_exercise_attemp.	sum_exercise_attemp	sum_exercise_attemp	sum_exercise_attemp	sum_exercise_attemp	sum_exercise_attemp	result_delay_sum_10	result_delay_sum_9	esult_delay_sum_8
0.	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
0.	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
sum_result_5_wee	sum_result_4_week	sum_result_3_week	sum_result_2_week	sum_result_1_week	sum_exercise_attemp	sum_exercise_attemp	sum_exercise_attemp	um_exercise_attemp
0.	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
0.	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
mean_result_4_wee	mean_result_3_week	mean_result_2_week	mean_result_1_week	sum_result_10_week	sum_result_9_week	sum_result_8_week	sum_result_7_week	sum_result_6_week
	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
0.		0.0	0.0	0.0	0.0	0.0	0.0	0.0
0.	0.0	0.0	0.0					
0.				mean result 9 week	mean result 8 week	mean result 7 week	mean result 6 week	mean result 5 week
	0.0 progress_2_week 0.0	progress_1_week	mean_result_10_week	mean_result_9_week	mean_result_8_week	mean_result_7_week	mean_result_6_week	mean_result_5_week

```
# Формируем стратифицированную обучающую выборку
import pandas as pd
# Предполагаем, что df уже определен
# Шаг 1: Выбор 30 записей из группы course_id=3
group_3_sample = df[df['course_id'] == 3].sample(n=30, replace=True)
# Шаг 2: Размножение выбранных записей до 500
group_3_expanded = group_3_sample.sample(n=500, replace=True)
# Шаг 3: Выбор 15 записей из группы course_id=77
group_77_sample = df[df['course_id'] == 77].sample(n=15, replace=True)
# Шаг 4: Размножение выбранных записей до 500
group_77_expanded = group_77_sample.sample(n=500, replace=True)
# Шаг 5: Получение стратифицированной выборки по 500 образцов из остальных групп
other groups = df[df['course id'] != 77]
other_groups = other_groups[other_groups['course_id'] != 3] # Исключаем группу course_id=3
# Получаем уникальные значения course_id для остальных групп
other_course_ids = other_groups['course_id'].unique()
# Проверяем, что у нас есть как минимум две другие группы
if len(other_course_ids) < 2:</pre>
    raise ValueError("Ожидается как минимум две другие группы.")
# Шаг 6: Выбор по 500 образцов из каждой другой группы
stratified_samples = []
for course_id in other_course_ids:
    samples = other_groups[other_groups['course_id'] == course_id].sample(n=500, replace=True)
    stratified_samples.append(samples)
# Объединение всех выборок
train_sample = pd.concat([group_3_expanded, group_77_expanded] + stratified_samples)
# Проверка результата
print("\nРазмер итоговой выборки:", len(train_sample))
print("\nКоличество записей из course_id=3:", len(train_sample[train_sample['course_id'] == 3]))
print("\nKoличество записей из course_id=77:", len(train_sample[train_sample['course_id'] == 77]))
print("\nКоличество записей из других групп:")
for course_id in other_course_ids:
    print(f"course_id={course_id}: {len(train_sample[train_sample['course_id'] == course_id])}")
```

```
Количество записей из course_id=3: 500

Количество записей из других групп:
course_id=71: 500

# Создаем валидационную выборку методом исключения из датасета обучающих примеров
val_sample = df.drop(train_sample.index)

# Проверка результатов
print("Обучающая стратифицированная выборка:")
print(len(train_sample))
print("\nВалидационная выборка:")
print(len(val_sample))

Обучающая стратифицированная выборка:
2000
```

Валидационная выборка: 1880

Размер итоговой выборки: 2000

```
# οcmamκu 77 εpynnu dna mecmupoβahua

df_71_test = val_sample[val_sample['course_id'] == 77]

df_71_test = val_sample[val_sample['course_id'] == 71]

df_49_test = val_sample[val_sample['course_id'] == 49]

df_3_test = val_sample[val_sample['course_id'] == 3]
```

df\_3\_test

	user_id	course_id	age	payment	tg_bot	m2_delay	view_delay_first_1_week	view_delay_first_2_week	view_delay_first_3_week
50	31678	3	15	0	1	-58.458332	-4.496157	-2.752473	-2.886936
73	33026	3	19	0	1	-45.245810	-3.194155	-2,963096	-3.352257
238	51059	3	19	0	2	0.725949	266.864600	25.554272	25.554272
341	55218	3	15	1	1	0.671539	0.000000	0.000000	0.000000
494	66184	3	18	0	1	-58.458332	12.727256	12.727256	12.727256
508	66405	3	19	0	1	8.577789	13.070785	12.799987	12.799987
1335	69383	3	19	0	2	-0.379537	0.000000	-4.597754	-4.212048

#### Выводы:

- в датасете нет пропусков, он хорошо подходит для обучения моделей;
- для прогнозирования целевого признака m2\_progress в различные периоды необходимо сформировать датасеты для каждой недели, что позволит исключить "подглядывание в будущее".
- 1.3. Создание отдельных датасетов для каждой недели

```
# train sample.columns.tolist()
from itertools import chain
# Определяем названия столбцов для каждой недели
sum_exercise_week_10 = [f'sum_exercise_{i} week' for i in range(1, 11)]
sum_required_exercises_week_10 = [f'sum_required_exercises_{i}_week' for i in range(1, 11)]
result_delay_sum_week_10 = [f'result_delay_sum_{i}_week' for i in range(1, 11)]
sum_exercise_attempts_mean_week_10 = [f'sum_exercise_attempts_mean_{i}week' for i in range(1, 11)]
sum_result_week_10 = [f'sum_result_{i}_week' for i in range(1, 11)]
mean_result_week_10 = [f'mean_result_{i}_week' for i in range(1, 11)]
progress_week_10 = [f'progress_{i}_week' for i in range(1, 11)]
view_delay_first_week_10 = [f'view_delay_first_{i}_week' for i in range(1, 11)]
view_delay_sum_week_10 = [f'view_delay_sum_{i}_week' for i in range(1, 11)]
# sum_activity_viewed_week_10 = [f'sum_activity_viewed_{i}_week' for i in range(1, 11)]
# sum_required_activity_viewed_week_10 = [f'sum_required_activity_viewed_{i}_week' for i in range(1, 11)]
# exercise_delay_first_week_10 = [f'exercise_delay_first_{i}_week' for i in range(1, 11)]
exercise delay sum week 10 = [f'exercise delay sum {i} week' for i in range(1, 11)]
# Уменьшаем количество элементов в списке для каждой последующей недели
def generate_weekly_columns(base_list, weeks):
    return [base_list[:i] for i in range(1, weeks + 1)]
# Генерируем названия столбцов по неделям
sum_exercise_weeks = generate_weekly_columns(sum_exercise_week_10, 10)
sum_required_exercises_weeks = generate_weekly_columns(sum_required_exercises_week_10, 10)
result_delay_sum_weeks = generate_weekly_columns(result_delay_sum_week_10, 10)
sum_exercise_attempts_mean_weeks = generate_weekly_columns(sum_exercise_attempts_mean_week_10, 10)
sum_result_weeks = generate_weekly_columns(sum_result_week_10, 10)
mean_result_weeks = generate_weekly_columns(mean_result_week_10, 10)
progress_weeks = generate_weekly_columns(progress_week_10, 10)
view delay first weeks = generate weekly columns(view delay first week 10, 10)
view_delay_sum_weeks = generate_weekly_columns(view_delay_sum_week_10, 10)
# sum_activity_viewed_weeks = generate_weekly_columns(sum_activity_viewed_week_10, 10)
# sum_required_activity_viewed_weeks = generate_weekly_columns(sum_required_activity_viewed_week_10, 10)
```

```
# Формируем столбцы для каждой недели
columns = []
for i in range(10):
   columns.append(list(chain(
       ['user_id', 'age', 'payment', 'tg_bot', 'm2_delay'],
       view_delay_first_weeks[i],
       view_delay_sum_weeks[i],
       sum_exercise_weeks[i],
       sum_required_exercises_weeks[i],
       # exercise_delay_first_weeks[i],
       result_delay_sum_weeks[i],
       sum_exercise_attempts_mean_weeks[i],
       sum_result_weeks[i],
       mean_result_weeks[i],
       progress_weeks[i],
       # view_delay_sum_weeks[i],
       # sum_activity_viewed_weeks[i],
       # sum required activity viewed weeks[i],
       exercise_delay_sum_weeks[i],
        ['m2_progress']
   )))
# Теперь на позиции `columns[0]` у нас находятся столбцы для 1-й недели,
# на `columns[1]` для 2-й и так далее до 10-й недели.
```

# exercise\_delay\_first\_weeks = generate\_weekly\_columns(exercise\_delay\_first\_week\_10, 10)
exercise\_delay\_sum\_weeks = generate\_weekly\_columns(exercise\_delay\_sum\_week\_10, 10)

```
Week 1 - Mean Absolute Error: 7.9924794391680525
Week 2 - Mean Absolute Error: 6.924550653267929
Week 3 - Mean Absolute Error: 6.700902867699872
Week 4 - Mean Absolute Error: 6.300852912703257
Week 5 - Mean Absolute Error: 5.999639314988462
Week 6 - Mean Absolute Error: 5.704828925945423
Week 7 - Mean Absolute Error: 4.9113169553779565
Week 8 - Mean Absolute Error: 3.818703643099225
Week 9 - Mean Absolute Error: 2.934018585007375
Week 10 - Mean Absolute Error: 2.8606435373430092
```

#### rf\_models

```
# Сериализация моделей!!!
import joblib # Импортируем библиотеку для сериализации
import os
# Укажите директорию для сохранения моделей
model_dir = '/home/shared_notebooks/zloy/saved_models'
# Создаем директорию, если она не существует
os.makedirs(model dir, exist ok=True)
{'rf model week 1': RandomForestRegressor(max features='log2', n_estimators=50),
 'rf model week 2': RandomForestRegressor(max features='log2', n estimators=50),
 'rf_model_week_3': RandomForestRegressor(max_features='log2', n_estimators=50),
 'rf_model_week_4': RandomForestRegressor(max_depth=30, max_features='log2', n_estimators=200),
 'rf_model_week_5': RandomForestRegressor(max_features='log2', n_estimators=50),
 'rf_model_week_6': RandomForestRegressor(max_features='log2', n_estimators=200),
 'rf model week 7': RandomForestRegressor(max features='sqrt', n estimators=200),
 'rf model week 8': RandomForestRegressor(max features='sqrt', n_estimators=200),
 'rf_model_week_9': RandomForestRegressor(max_features='sqrt', n_estimators=200),
 'rf_model_week_10': RandomForestRegressor(max_features='sqrt', n_estimators=200)}
# Сериализация моделей на диск
for model name, model in rf models.items():
   model_filename = os.path.join(model_dir, f'{model_name}.joblib') # Создаем имя файла для модели
    joblib.dump(model, model_filename) # Сохраняем модель в файл
    print(f"Модель '{model_name}' успешно сохранена в '{model_filename}'")
print(f"\nВсе модели успешно сохранены в директорию: {model_dir}")
```

# В результате получены модели

rf_model_week_1.joblib	8 минут назад
rf_model_week_10.joblib	8 минут назад
rf_model_week_2.joblib	8 минут назад
rf_model_week_3.joblib	8 минут назад
rf_model_week_4.joblib	8 минут назад
rf_model_week_5.joblib	8 минут назад
rf_model_week_6.joblib	8 минут назад
rf_model_week_7.joblib	8 минут назад
rf_model_week_8.joblib	8 минут назад
rf_model_week_9.joblib	8 минут назад
Untitled.ipynb	24 минуты назад

На данный момент идет работа и проверка гипотез